Laporan Ujian Tengah Semester Data Science

ANALISIS POLA KEBIASAAN HIDUP DAN KARAKTERISTIK INDIVIDU PADA BERBAGAI KATEGORI STATUS OBESITAS

Disusun oleh:

1. Hasan (123240041)
2. Nurjelita Sukmawati (123240046)
3. Haerunisa (123240047)
4. Puput Septiani (123240263)

Dosen Pengampu:

Dhimas Arief Dharmawan, S.T., Ph.D.

PROGRAM STUDI INFORMATIKA
JURUSAN INFORMATIKA
FAKULTAS TEKNIK INDUSTRI
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
YOGYAKARTA

2026

KATA PENGANTAR

Puji syukur ke hadirat Tuhan Yang Maha Esa atas rahmat dan karunia-Nya sehingga laporan Ujian Tengah Semester mata kuliah Data Science yang berjudul "Analisis Pola Kebiasaan Hidup Dan Karakteristik Individu Pada Berbagai Kategori Status Obesitas" dapat disusun.

Laporan ini disusun sebagai bagian dari pemenuhan tugas proyek Ujian Tengah Semester Data Science Tahun Ajaran 2026/2027. Pembahasan laporan difokuskan pada tahap Business Understanding dan Data Understanding dalam kerangka CRISP-DM, meliputi perumusan masalah, tujuan penelitian, pemetaan stakeholder, pemahaman struktur dan kualitas dataset, serta eksplorasi awal terhadap data Obesity Prediction.

Penulis menyadari bahwa laporan ini masih memiliki keterbatasan, khususnya pada verifikasi sumber asli dan lisensi dataset serta validasi lanjutan terhadap hasil analisis. Oleh karena itu, kritik dan saran yang membangun diharapkan untuk penyempurnaan laporan dan pengembangan proyek pada tahap berikutnya

Semoga laporan ini dapat memberikan manfaat sebagai sarana pembelajaran penerapan Data Science dan menjadi dasar untuk proses analisis yang lebih mendalam.

Yogyakarta, 26 Oktober 2026

Penyusun

DAFTAR ISI

HALAMAN JUDUL ..... **i**
KATA PENGANTAR ..... **ii**
DAFTAR ISI ..... **iii**
BAB I BUSINESS UNDERSTANDING **1**
1.1 Latar Belakang 1
1.2 Peryataan Masalah dan Stakeholder 1
1.3 Tujuan SMART 2
1.4 Matriks Keberhasilan 2
1.5 Asumsi dan Batasan 2
1.6 Risiko, Etika dan Mitigasi 3
1.7 Nilai Bisnis/Use Case 3
1.8 Pemetaan Stakeholder – Data 4
BAB II DATA UNDERSTANDING **5**
2.1. Sumber Data dan Lisensi/Izin 5
2.2. Data Dictionary 7
2.3. Kualitas Data ..... **Error! Bookmark not defined.**
2.4. EDA Berinsight 10
2.5. Representativitas dan Bias Sampel 13
DAFTAR PUSTAKA **16**
LAMPIRAN **17**

BAB I
BUSINES UNDERSTANDING

1.1 Latar Belakang

Obesitas dan status berat badan merupakan isu kesehatan yang dipengaruhi oleh berbagai karakteristik individu dan kebiasaan hidup. Data mengenai usia, tinggi badan, berat badan, kebiasaan makan, konsumsi air, aktivitas fisik, penggunaan perangkat teknologi, serta moda transportasi dapat dieksplorasi untuk memahami pola yang muncul pada kategori status berat badan.

Proyek ini menggunakan dataset Obesity Prediction untuk melakukan analisis eksploratif dan merancang pendekatan klasifikasi berbasis machine learning. Analisis diarahkan untuk memahami karakteristik data dan mengevaluasi kemampuan model dalam mengklasifikasikan tujuh kategori yang tercantum pada kolom target. Hasil model diposisikan sebagai keluaran analitis pada dataset, bukan sebagai diagnosis medis atau bukti hubungan sebab-akibat.

1.2 Peryataan Masalah dan Stakeholder

Permasalahannya adalah banyak individu, khususnya kaum muda, belum sepenuhnya menyadari bahwa pola kebiasaan keseharian mereka telah membawa risiko kesehatan. Sementara itu, evaluasi status berat badan secara klinis mensyaratkan adanya pengukuran fisik secara langsung. Proyek ini bertujuan untuk mengembangkan sebuah model klasifikasi yang mampu memprediksi tingkat risiko obesitas ke dalam tujuh kategori, berdasarkan pola makan, aktivitas fisik, dan data demografis dasar, tanpa mengikutsertakan data tinggi dan berat badan

Stakeholder yang diusulkan dalam proyek ini meliputi masyarakat umum sebagai calon pengguna informasi mengenai pola kebiasaan hidup dan karakteristik individu pada berbagai kategori status obesitas; tenaga kesehatan sebagai pihak yang dapat memanfaatkan hasil analisis sebagai informasi pendukung dalam edukasi kesehatan; pihak kampus sebagai institusi yang dapat memanfaatkan hasil proyek untuk mendukung kegiatan akademik dan pengembangan penelitian; mahasiswa/peneliti sebagai pihak yang mengolah data, melakukan analisis eksploratif, dan menyusun interpretasi hasil; serta dosen pengampu sebagai pembimbing akademik yang memberikan arahan dan mengevaluasi proses maupun hasil proyek.

1.3 Tujuan SMART

Tabel 1.1 Tujuan SMART

Unsur SMART	Perumusan
Specific	Menganalisis dataset dan mengembangkan model klasifikasi untuk tujuh kategori pada kolom Obesity.
Measurable	Melaporkan hasil EDA dan mengukur model dengan macro F1-score, akurasi, precision, recall, serta confusion matrix.
Achievable	Menggunakan 2.111 baris data yang tersedia dan perangkat Python/Pandas/scikit-learn.
Relevant	Memberikan contoh penerapan Data Science untuk eksplorasi dan klasifikasi status berat badan.
Time-bound	Tahap Business Understanding dan Data Understanding diselesaikan untuk laporan UTS; persiapan data dan pemodelan dilanjutkan pada tahap proyek berikutnya.

1.4 Matriks Keberhasilan

Secara Teknis:

- Akurasi minimal 80% (target usulan, belum diuji; hanya dinilai jika model klasifikasi benar-benar dibuat dan diuji).
- Macro F1 minimal 0,78 pada data uji (target usulan, belum diuji).
- Recal kelas obesitas (Type I-III) minimal 0,85 (target usulan, bukan hasil aktual; relevan jika pemodelan dilakukan).

Secara Manfaat:

- Faktor penting model dapat dijelaskan dengan bahasa awam.
- Jika pemodelan dilakukan, selisih recall antargender akan ditinjau; ambang 10 poin persentase merupakan target usulan, bukan hasil aktual.

1.5 Asumsi dan Batasan

Asumsi:

- Jawaban kuesioner responden dianggap jujur dan benar.
- Label obesitas pada dataset dihitung dengan benar dari IMT menurut klasifikasi WHO.

Batasan:

- Sekitar 77% dari data adalah data sintetis (SMOTE); hanya 23% dari responden nyata.

- Responden berasal dari Meksiko, Peru, dan Kolombia, sehingga belum tentu mewakili populasi Indonesia.
- Mayoritas responden berusia muda (83% berusia ≤ 30 tahun).
- Model bukan alat diagnosis medis, dan waktu pengerjaan terbatas dengan laptop pribadi.

1.6 Risiko, Etika dan Mitigasi

Risiko Tenis:

- Label dihitung dari IMT (berat ÷ tinggi²), sehingga memakai Height dan Weight sebagai fitur menyebabkan kebocoran data (leakage).
  Mitigasi: Height dan Weight dikeluarkan dari fitur dan hanya dipakai pada EDA.
- Data sintetis membuat titik yang mirip tersebar di data latih dan uji, sehingga metrik terlalu optimis.
  Mitigasi: duplikat dihapus, memakai stratified cross-validation, dan hasil dilaporkan dengan catatan batasan.

Risiko Etika dan Bias

- Kelas Obesity Type II hampir seluruhnya laki-laki dan Type III hampir seluruhnya perempuan, sehingga model bisa bergantung pada gender.
  Mitigasi: evaluasi per gender serta membandingkan model dengan dan tanpa fitur Gender.
- Label "obesitas" dapat menimbulkan stigma.
  Mitigasi: bahasa hasil dibuat netral dan disertai pernyataan bahwa ini bukan diagnosis.

Aspek Legal

- Dataset dirujuk dari UCI Machine Learning Repository dan publikasi Palechor & De la Hoz Manotas (2019). Sebelum pengumpulan, pastikan kembali halaman sumber resmi, ketentuan lisensi CC BY 4.0, serta atribusi yang diwajibkan. Cantumkan sumber unduhan Kaggle sebagai salinan/tautan akses jika memang itu berkas yang digunakan.

1.7 Nilai Bisnis/Use Case

- Untuk masyarakat: hasil analisis dapat menjadi bahan edukasi umum tentang pola kebiasaan hidup, bukan alat skrining atau diagnosis mandiri.
- Untuk mahasiswa: pengalaman menerapkan CRISP-DM pada masalah kesehatan nyata.

Sebagai pengembangan lanjutan, temuan dapat ditampilkan melalui dashboard edukatif sederhana setelah validasi dan evaluasi yang sesuai. Pengembangan ini belum menjadi fungsi yang tervalidasi pada laporan UTS.

1.8 Pemetaan Stakeholder – Data

Tabel 1.2 Pemetaan Stakeholder – Data

Stakeholder	Peran / Kebutuhan	Hubungan dengan Data
Mahasiswa	Melaksanakan proyek, mengolah dan menganalisis data.	Mengumpulkan, membersihkan, dan memodelkan data kuesioner.
Dosen Pengampu	Memberi arahan dan menilai hasil proyek.	Memantau proses analisis dan hasil akhir.
Masyarakat Umum	Pengguna akhir yang membutuhkan skrining risiko.	Sumber data kuesioner dan penerima hasil prediksi.
Tenaga Kesehatan	Triase dan konseling berbasis risiko.	Pengguna hasil prediksi untuk prioritas konsultasi.

BAB II

DATA UNDERSTANDING

2.1. Sumber Data dan Lisensi/Izin

Tabel 2.1 Sumber Data dan Lisensi

Kategori	Keterangan
Sumber Data	UCI Machine Learning Repository – *Estimation of Obesity Levels Based on Eating Habits and Physical Condition* (Palechor & De la Hoz Manotas, 2019)
Tautan Dataset	https://www.kaggle.com/datasets/ruchikakumbhar/obesity-prediction
Lisensi/Izin	Creative Commons Attribution 4.0 (CC BY 4.0): boleh dipakai dengan menyebut atribusi.
Asal-usul Data	Survei daring anonim dari responden di Meksiko, Peru, dan Kolombia. Sebanyak 23% data nyata dan 77% sintetis hasil SMOTE (Chawla et al., 2002).
Metodologi Generasi Data	Data sintetis dibuat dengan filter SMOTE (Weka), yaitu membuat titik baru dengan interpolasi linear antara sebuah responden dan tetangga terdekatnya pada kelas yang sama, sampai tiap kelas seimbang. Asumsi: titik hasil interpolasi mewakili responden yang masuk akal. Batasan: kombinasi jawaban bisa tidak realistis (misalnya nilai ordinal pecahan), keragaman antar responden berkurang, dan baris sintetis tidak dapat dibedakan dari data nyata.
Skema	2.111 baris × 17 kolom (16 fitur + 1 target), tanpa nilai kosong.

Source Code 2.1 Pemeriksaan dan Pembacaan Dataset

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from pathlib import Path

sns.set_theme(style="whitegrid")

# Periksa lokasi file
```

```
file_path = Path("Obesity_prediction.csv")

print("Folder kerja:", Path.cwd())
print("Lokasi dataset:", file_path.resolve())
print("File ditemukan:", file_path.exists())

if not file_path.exists():
    raise FileNotFoundError("File Obesity_prediction.csv tidak
ditemukan!")

# Baca dataset
df = pd.read_csv(file_path)

# Periksa dataset
print("Ukuran dataset:", df.shape)
print("\nTipe data setiap kolom:")
print(df.dtypes)

# Tampilkan 5 baris pertama
display(df.head())
```

```
Folder kerja: d:\Coding
Lokasi dataset: D:\Coding\Obesity_prediction.csv
File ditemukan: True
Ukuran dataset: (2111, 17)

Tipe data setiap kolom:
Gender                str
Age               float64
Height            float64
Weight            float64
family_history        str
FAVC                  str
FCVC              float64
NCP               float64
CAEC                  str
SMOKE                 str
CH2O              float64
SCC                   str
FAF               float64
TUE               float64
CALC                  str
MTRANS                str
Obesity               str
dtype: object
```

	Gender	Age	Height	Weight	family_history	FAVC	FCVC	NCP	CAEC	SMOKE	CH2O	SCC	FAF	TUE	CALC	MTRANS	Obesity
0	Female	21.0	1.62	64.0	yes	no	2.0	3.0	Sometimes	no	2.0	no	0.0	1.0	no	Public_Transportation	Normal_Weight
1	Female	21.0	1.52	56.0	yes	no	3.0	3.0	Sometimes	yes	3.0	yes	3.0	0.0	Sometimes	Public_Transportation	Normal_Weight
2	Male	23.0	1.80	77.0	yes	no	2.0	3.0	Sometimes	no	2.0	no	2.0	1.0	Frequently	Public_Transportation	Normal_Weight
3	Male	27.0	1.80	87.0	no	no	3.0	3.0	Sometimes	no	2.0	no	2.0	0.0	Frequently	Walking	Overweight_Level_I
4	Male	22.0	1.78	89.8	no	no	2.0	1.0	Sometimes	no	2.0	no	0.0	0.0	Sometimes	Public_Transportation	Overweight_Level_II

Gambar 2.1 Pemeriksaan dan Pembacaan Dataset

2.2. Data Dictionary

Tabel 2.2 Data Dictionary

No	Variabel	Tipe	Unit/Nilai
1	Gender	Kategorikal	Male, Female
2	Age	Numerik	Usia (tahun)
3	Height	Numerik	Tinggi badan (meter)
4	Weight	Numerik	Berat badan (kg)
5	family_history	Kategorikal	Riwayat keluarga overweight (yes/no)
6	FAVC	Kategorikal	Sering makan makanan tinggi kalori (yes/no)
7	FCVC	Ordinal	Frekuensi konsumsi sayur (1–3)
8	NCP	Ordinal	Jumlah makan utama per hari (1–4)
9	CAEC	Kategorikal	Camilan antar waktu makan (no, Sometimes, Frequently, Always)
10	SMOKE	Kategorikal	Merokok (yes/no)
11	CH2O	Ordinal	Konsumsi air harian (1–3)
12	SCC	Kategorikal	Memantau asupan kalori (yes/no)
13	FAF	Ordinal	Frekuensi aktivitas fisik (0–3)
14	TUE	Ordinal	Waktu penggunaan gawai (0–2)
15	CALC	Kategorikal	Konsumsi alkohol (no, Sometimes, Frequently, Always)
16	MTRANS	Kategorikal	Moda transportasi (Automobile, Bike, Motorbike, Public_Transportation, Walking)
17	Obesity	Target (ordinal)	7 kelas: Insufficient_Weight s.d. Obesity_Type_III

2.3. Kualitas Data

a. Missing Value

Source Code 2.2 Pemeriksaan Missing Value

```
# Ringkasan missing value
missing_data = pd.DataFrame({
    "Variabel": df.columns,
    "Jumlah": df.isna().sum().values,
})
```

```
missing_data["Persentase (%)"] = (
    missing_data["Jumlah"] / len(df) * 100
).round(2)
display(missing_data)
```

	Variabel	Jumlah	Persentase (%)
0	Gender	0	0.0
1	Age	0	0.0
2	Height	0	0.0
3	Weight	0	0.0
4	family_history	0	0.0
5	FAVC	0	0.0
6	FCVC	0	0.0
7	NCP	0	0.0
8	CAEC	0	0.0
9	SMOKE	0	0.0
10	CH2O	0	0.0
11	SCC	0	0.0
12	FAF	0	0.0
13	TUE	0	0.0
14	CALC	0	0.0
15	MTRANS	0	0.0
16	Obesity	0	0.0

Gambar 2.2 Pemeriksaan Missing Value

Seluruh kolom memiliki 0 nilai kosong (0%), sehingga tidak perlu imputasi.

b. Duplikasi Data

Source Code 2.3 Pemeriksaan Duplikasi Data

```
# Hitung baris duplikat
jumlah_duplikat = df.duplicated().sum()
print(f"Jumlah baris duplikat: {jumlah_duplikat}")

# Distribusi label pada baris yang terduplikasi (jika ada)
if jumlah_duplikat > 0 and "Obesity" in df.columns:
    display(df.loc[df.duplicated(keep=False),
"Obesity"].value_counts())
```

```
Jumlah data duplikat: 24
Obesity
Overweight_Level_I     15
Normal_Weight          10
Insufficient_Weight     8
Name: count, dtype: int64
```

Gambar 2.3 Pemeriksaan Duplikasi Data

Ditemukan 24 baris duplikat (33 baris terlibat) yang akan dihapus pada tahap. Data Preparation agar baris yang sama tidak muncul di data latih dan uji.

c. Outlier

Source Code 2.4 Pemeriksaan Outlier

```
# Variabel numerik yang diperiksa
kolom_numerik = ["Age", "Height", "Weight", "FCVC", "NCP",
"CH2O", "FAF", "TUE"]


def outlier_iqr(data, column):
    """Kembalikan jumlah, persentase, dan batas outlier
berdasarkan IQR."""
    q1 = data[column].quantile(0.25)
    q3 = data[column].quantile(0.75)
    iqr = q3 - q1
    batas_bawah = q1 - 1.5 * iqr
    batas_atas = q3 + 1.5 * iqr
    mask = (data[column] < batas_bawah) | (data[column] >
batas_atas)
    jumlah = int(mask.sum())
    persentase = jumlah / len(data) * 100
    return jumlah, persentase, batas_bawah, batas_atas

hasil_outlier = []
for kolom in kolom_numerik:
    jumlah, persentase, bawah, atas = outlier_iqr(df, kolom)
    hasil_outlier.append([kolom, jumlah, round(persentase,
2), round(bawah, 2), round(atas, 2)])

outlier_df = pd.DataFrame(
    hasil_outlier,
    columns=["Variabel", "Jumlah Outlier", "Persentase (%)",
"Batas Bawah", "Batas Atas"],
)
display(outlier_df)
```

	Variabel	Jumlah Outlier	Persentase (%)	Batas Bawah	Batas Atas
0	Age	168	7.96	10.87	35.08
1	Height	1	0.05	1.42	1.98
2	Weight	1	0.05	2.54	170.37
3	FCVC	0	0.00	0.50	4.50
4	NCP	579	27.43	2.15	3.51
5	CH2O	0	0.00	0.25	3.82
6	FAF	0	0.00	-2.19	3.98
7	TUE	0	0.00	-1.50	2.50

Gambar 2.4 Pemeriksaan Outlier

Variabel Age memiliki 168 outlier (7,96%) pada usia di atas 35 tahun yang wajar (responden dewasa), sehingga dipertahankan. NCP menunjukkan 27,43% "outlier" karena variabel ini diskret dan sangat condong ke nilai 3, jadi bukan outlier sebenarnya. Height dan Weight masing-masing hanya 1 titik ekstrem yang masih valid. Seluruh outlier dipertahankan.

2.4. EDA Berinsight

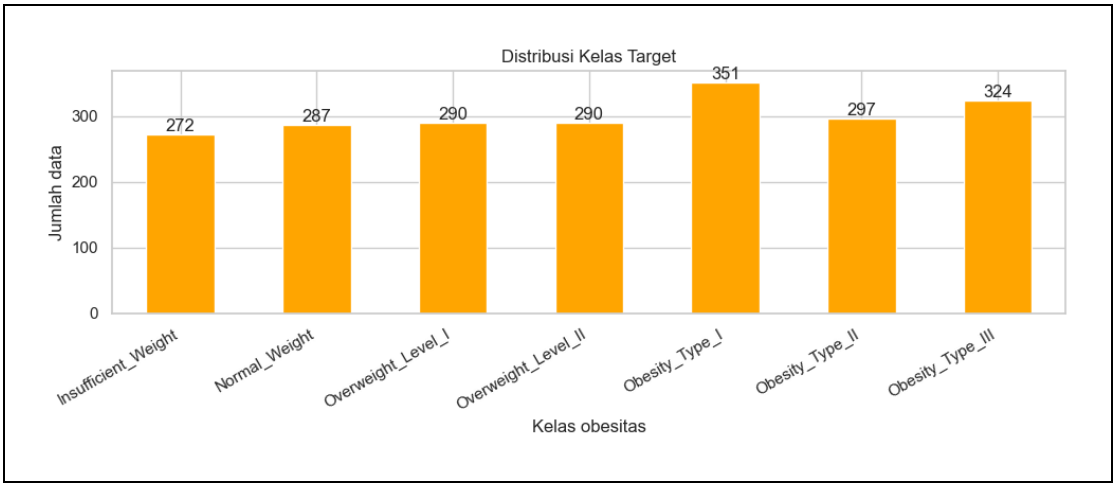
a. Distribusi Data

Source Code 2.5 Visualisasi Distribusi Kelas Target

```
# Distribusi kelas target
order = [
    "Insufficient_Weight",
    "Normal_Weight",
    "Overweight_Level_I",
    "Overweight_Level_II",
    "Obesity_Type_I",
    "Obesity_Type_II",
    "Obesity_Type_III",
]

jumlah_kelas = df["Obesity"].value_counts().reindex(order,
fill_value=0)
ax = jumlah_kelas.plot(kind="bar", figsize=(10, 4),
color="orange")
ax.bar_label(ax.containers[0])
ax.set_title("Distribusi Kelas Target")
ax.set_xlabel("Kelas obesitas")
ax.set_ylabel("Jumlah data")
plt.xticks(rotation=30, ha="right")
```

```
plt.tight_layout()
plt.show()
```

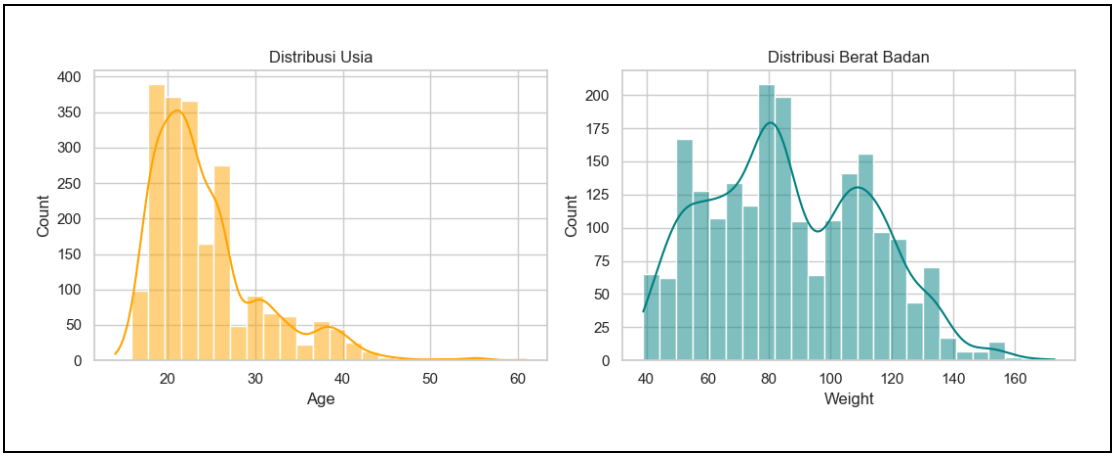


Gambar 2.5 Distribusi kelas target

Kelas relatif seimbang (272–351 baris per kelas). Keseimbangan ini hasil SMOTE, bukan cerminan populasi nyata, sehingga akurasi pada data ini belum tentu sama di lapangan.

Source Code 2.6 Visualisasi Distribusi Usia dan Berat Badan

```
# Distribusi usia dan berat badan
fig, axs = plt.subplots(1, 2, figsize=(11, 4))
sns.histplot(data=df, x="Age", bins=25, kde=True, ax=axs[0],
color="orange")
axs[0].set_title("Distribusi Usia")
sns.histplot(data=df, x="Weight", bins=25, kde=True,
ax=axs[1], color="teal")
axs[1].set_title("Distribusi Berat Badan")
plt.tight_layout()
plt.show()
```



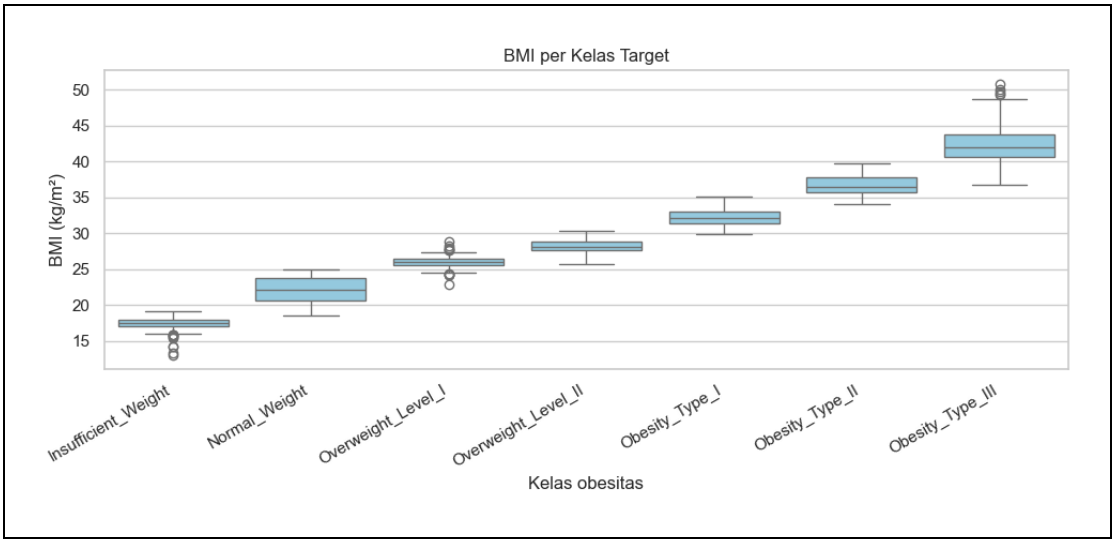
Gambar 2.6 Distribusi Usia dan Berat Badan

Usia menceng ke kanan dengan median 22,8 tahun dan 83% responden berusia ≤ 30 tahun. Berat badan tersebar 39–173 kg (rerata 86,6 kg).

Source Code 2.7 Perhitungan dan Visualisasi BMI

```
# Hitung BMI dari berat (kg) dan tinggi (meter)
df["BMI"] = df["Weight"] / (df["Height"] ** 2)

plt.figure(figsize=(10, 4.5))
sns.boxplot(data=df, x="Obesity", y="BMI", order=order,
color="skyblue")
plt.title("BMI per Kelas Target")
plt.xlabel("Kelas obesitas")
plt.ylabel("BMI (kg/m²)")
plt.xticks(rotation=30, ha="right")
plt.tight_layout()
plt.show()
```



Gambar 2.7 Visualisasi BMI per Kelas Target

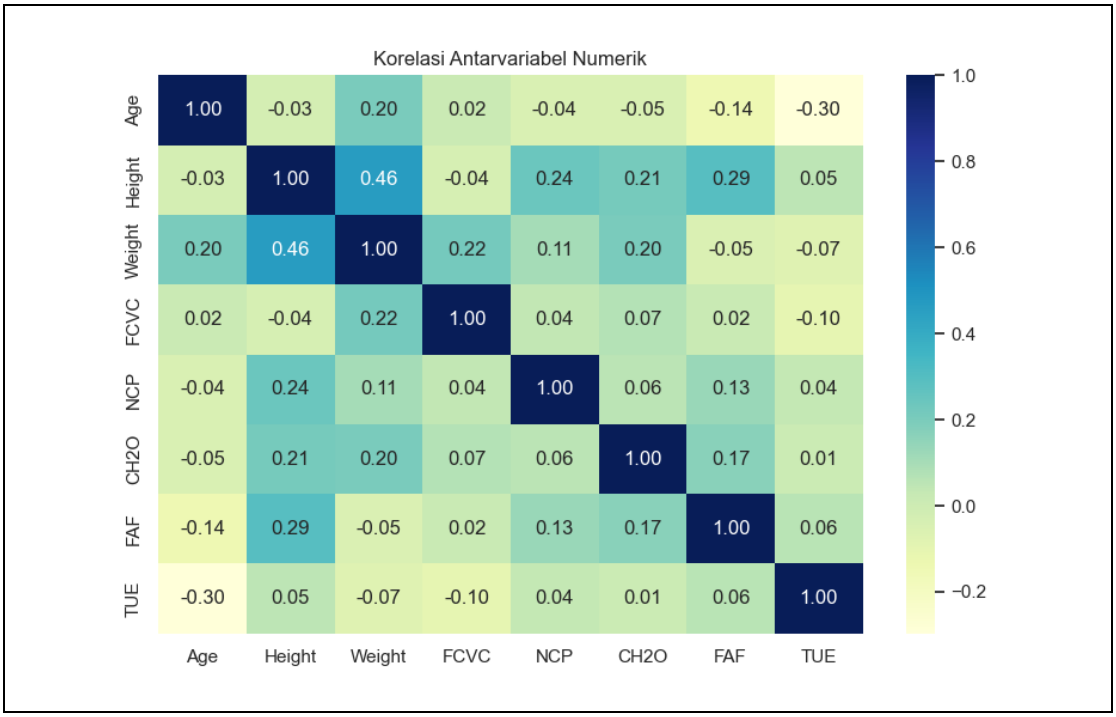
IMT naik berurutan mengikuti kelas dan hampir sesuai ambang WHO, artinya label adalah fungsi dari Height dan Weight. Karena itu keduanya tidak dipakai sebagai fitur model.

b. Korelasi Antarvariabel

Source Code 2.8 Visualisasi Korelasi Antarvariabel

```
# Heatmap korelasi fitur numerik
plt.figure(figsize=(9, 6))
sns.heatmap(
    df[kolom_numerik].corr(numeric_only=True),
    annot=True,
    cmap="YlGnBu",
    fmt=".2f",
    vmin=-1,
```

```
    vmax=1,
)
plt.title("Korelasi Antarvariabel Numerik")
plt.tight_layout()
plt.show()
```



Gambar 2.8 Heatmap Korelasi Antarvariabel Numerik

Korelasi antar fitur perilaku tergolong lemah (|r| maksimum 0,30, yaitu Age–TUE sebesar −0,30), sehingga tidak ada multikolinearitas yang mengkhawatirkan. Hubungan fitur perilaku dengan target kemungkinan non-linear sehingga model berbasis pohon perlu diuji.

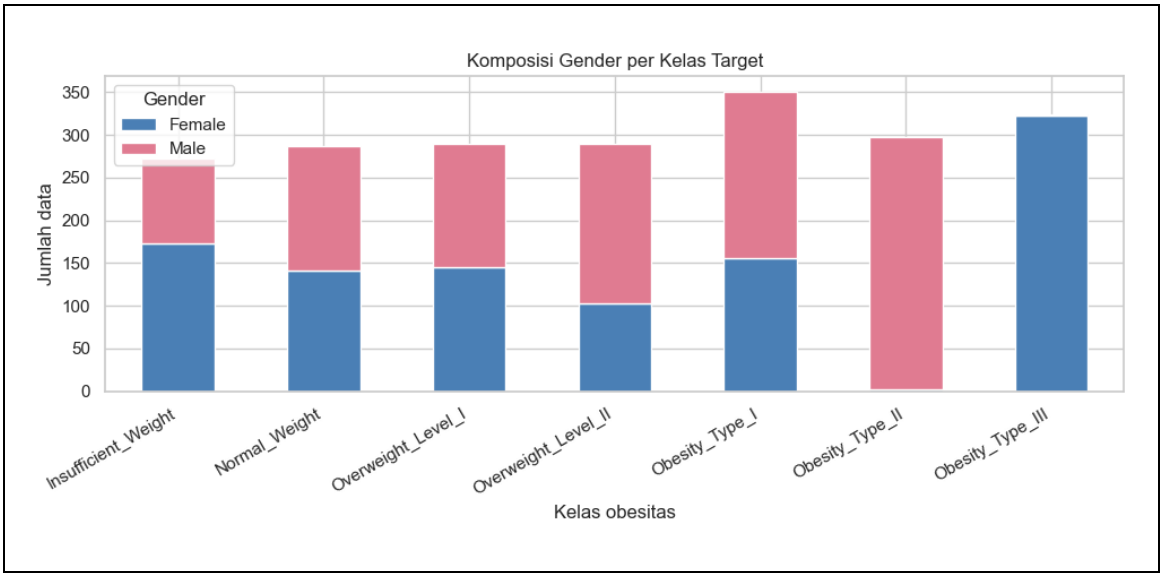
Hubungan fitur dengan target (hasil uji chi-square dan ANOVA pada notebook): fitur paling berasosiasi adalah Gender (Cramér's V 0,56), family_history (0,54), CAEC (0,36), FAVC (0,33), serta FCVC (F = 112,3) dan Age (F = 78,0). Persentase responden dengan riwayat keluarga naik dari 54% pada Normal Weight menjadi 98–100% pada Obesity Type I–III, sedangkan rerata frekuensi aktivitas fisik (FAF) turun dari 1,25 pada Normal Weight menjadi 0,66 pada Obesity Type III.

2.5. Representativitas dan Bias Sampel

Source Code 2.9 Analisis Komposisi Gender per Kelas

```
# Komposisi gender pada setiap kelas target
tabel_gender = pd.crosstab(df["Obesity"],
df["Gender"]).reindex(order, fill_value=0)
```

```
ax = tabel_gender.plot(kind="bar", stacked=True, figsize=(10,
4.5))
ax.set_title("Komposisi Gender per Kelas Target")
ax.set_xlabel("Kelas obesitas")
ax.set_ylabel("Jumlah data")
plt.xticks(rotation=30, ha="right")
plt.tight_layout()
plt.show()
```



Gambar 2.9 Komposisi Gender per Kelas Target

Tabel 2.3 Aspek Representativitas dan Bias Sampel

Aspek	Keterangan
Representativitas	Dataset memuat responden muda dari tiga negara Amerika Latin, sehingga cocok untuk skrining usia muda tetapi tidak mewakili usia lanjut maupun populasi Indonesia.
Bias Data Sintetis	Sekitar 77% data hasil SMOTE: kelas dibuat seimbang dan nilai ordinal menjadi pecahan (30–61% baris pada FCVC, NCP, CH2O, FAF, TUE).
Bias Gender	Obesity Type II hampir seluruhnya laki-laki (295 dari 297) dan Type III hampir seluruhnya perempuan (323 dari 324).
Kelas Type III Seragam	Seluruh responden berusia 18–26 tahun, 100% memiliki riwayat keluarga dan 323 dari 324 memakai transportasi umum. Pola ini tidak realistis dan mudah dihafal model.

Mitigasi Bias	Hapus duplikat, keluarkan Height dan Weight, gunakan stratified k-fold, bandingkan model dengan dan tanpa Gender, serta evaluasi per gender.

DAFTAR PUSTAKA

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic minority over-sampling technique*. *Journal of Artificial Intelligence Research*, 16, 321–357. https://doi.org/10.1613/jair.953

Palechor, F. M., & De la Hoz Manotas, A. (2019). *Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico.* Data in Brief, 25, 104344. https://doi.org/10.1016/j.dib.2019.104344

Palechor, F. M., & De la Hoz Manotas, A. (2019). *Estimation of obesity levels based on eating habits and physical condition [Dataset]*. UCI Machine Learning Repository. https://doi.org/10.24432/C5H31Z

World Health Organization. (2024). *Obesity and overweight [Fact sheet]*. https://www.who.int/news-room/fact-sheets/detail/obesity-and-overweight

LAMPIRAN

Portofolio dan Reprodusibilitas

Item	Keterangan
Tautan portofolio	https://drive.google.com/file/d/1mXaeW0XySrtv0iEUuPrK3r9kyw8UYGIg/view?usp=sharing
Notebook	Data_Understanding.ipynb
Dataset	https://www.kaggle.com/datasets/ruchikakumbhar/obesity-prediction
Library	Python 3, pandas, NumPy, Matplotlib, seaborn, dan pathlib.
Cara menjalankan	Letakkan file CSV di folder yang sama dengan notebook. Buka notebook menggunakan Jupyter Notebook atau Google Colab, pastikan nama/path dataset sesuai, lalu jalankan seluruh sel secara berurutan dengan Run All.
Pemeriksaan hasil	Pastikan notebook berjalan tanpa error dan hasil jumlah baris/kolom, pemeriksaan kualitas data, tabel, serta grafik muncul sesuai kode.
Catatan reproduksibilitas	Simpan notebook dan dataset yang digunakan bersama-sama. Jika menggunakan Google Colab, unggah dataset ke sesi atau hubungkan penyimpanan yang sesuai. Jangan mencantumkan tautan portofolio sebelum tautan tersedia dan dapat diakses.